



# Aprendizaje por refuerzo

Métodos de aprendizaje:

1. Aprendizaje supervisado  
(backpropagation en RNAs)




2. Aprendizaje no supervisado  
(mapa autoorganizativo en RNAs)



# Aprendizaje por refuerzo

## Métodos de aprendizaje:

1. Aprendizaje supervisado
2. Aprendizaje no supervisado
3. Aprendizaje por refuerzo



## CONDICIONAMIENTO CLASICO PAVLOV

Cuando se le presentaba al animal un trozo de carne, se observa que se incrementaba el flujo de saliva.

1. Antes del condicionamiento




Observó que luego de repetidas veces, el perro segregaba saliva abundante al sólo escuchar el sonido de la campana, aunque no se ofreciera ningún al

3. Durante el condicionamiento



En el proceso de experimentación, Pavlov hacía sonar una campana antes de presentarle el trozo de carne.

2. Antes del condicionamiento



CONCLUSION: El perro aprendió a salivar ante un estímulo neutro como la campana. A esta forma de aprendizaje se le conoce como CONDICIONAMIENTO CLÁSICO

4. Después del condicionamiento




## Definiciones:

- Política ( $\pi$ ): define cómo se comporta el sistema en cierto tiempo. Define una traslación (puede ser estocástica) de los estados a las acciones.
- Función de recompensa ( $R$ ): define la meta. Vincula cada estado-acción a un número, la recompensa o refuerzo, indicando cuán deseable es el estado.
- Función de valor ( $V$ ): indica lo que es bueno a largo plazo. Es la recompensa total que un agente puede esperar acumular empezando en ese estado (predicciones de recompensas). Se busca realizar acciones que den los valores más altos, no la recompensa mayor.

Las recompensas están dadas por el ambiente, pero los valores se deben de estimar (aprender) en función de las observaciones.

- Modelo del ambiente (opcional): imita el comportamiento del ambiente. Se puede usar para hacer planificación al considerar posibles situaciones futuras basadas en el modelo.



Esquema general del modelo de aprendizaje por refuerzo.

# Q-Learning

El objetivo del aprendizaje por refuerzo es encontrar una política  $\pi$ , que para cada estado en el que se encuentre el agente, indique cuál es la mejor acción que se puede ejecutar para alcanzar un objetivo dado; o traducido al aprendizaje por refuerzo, maximice alguna medida de refuerzo a largo plazo.

$$V^{\pi}(s_t) = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots = \sum_{i=0}^{\infty} \gamma^i r_{t+i}$$

Representa el valor acumulado de un estado  $s$  en el tiempo  $t$ , obtenido por seguir una política  $\pi$  desde el estado arbitrario  $s_t$

# Q-Learning

Política óptima:

$$\pi^* = \arg \max_{\pi} V^{\pi}(s), (\forall s)$$

$$\pi^* = \arg \max_a [R(s, a) + \gamma V^*(\delta(s, a))]$$

$$Q(s, a) = R(s, a) + \gamma V^*(\delta(s, a))$$

$$\pi^*(s) = \arg \max_a Q(s, a)$$

# Q-Learning

## *Algoritmo Q-learning ( $\mathcal{S}, \mathcal{A}$ )*


Para cada par ( $s \in \mathcal{S}$ ,  $a \in \mathcal{A}$ ) inicializar la tabla  $Q(s,a)$  a 0. Observar el estado actual  $s$ . Hacer para siempre: Seleccionar una acción  $a$  y ejecutarla

- Recibir el refuerzo inmediato  $r$
- Observar el nuevo estado  $s'$
- Actualizar la entrada de la tabla,  $Q(s,a)$  con la ecuación:

$$Q(s, a) \leftarrow r + \gamma \max_{a'} Q(s', a') \quad (9)$$

- Asignar a  $s$  el estado  $s'$

# Q-Learning - ejemplo



MDP determinista

Asumimos que hay un agente actuando en ese MDP. En un primer episodio, el agente se encuentra inicialmente en el estado  $s_1$ , y ejecuta la siguiente secuencia de acciones:  $s_1 \xrightarrow{a_1} s_2 \xrightarrow{a_3} s_3 \xrightarrow{a_3} s_4$ . La secuencia indica que el agente ejecuta desde  $s_1$  la acción  $a_1$ , transitando

- $Q(s_1, a_1) = \mathcal{R}(s_1, a_1) + \gamma \arg_a \max Q(s_2, a) = 0 + \gamma 0 = 0$
- $Q(s_2, a_3) = \mathcal{R}(s_2, a_3) + \gamma \arg_a \max Q(s_3, a) = 0 + \gamma 0 = 0$
- $Q(s_3, a_3) = \mathcal{R}(s_3, a_3) + \gamma \arg_a \max Q(s_4, a) = 1 + \gamma 0 = 1$


| $Q(s,a)$ | $a_1$ | $a_2$ | $a_3$ |
|----------|-------|-------|-------|
| $s_1$    | 0     | 0     | 0     |
| $s_2$    | 0     | 0     | 0     |
| $s_3$    | 0     | 0     | 0     |
| $s_4$    | 0     | 0     | 0     |

Matriz Q inicial para el MDP

| $Q(s,a)$ | $a_1$ | $a_2$ | $a_3$ |
|----------|-------|-------|-------|
| $s_1$    | 0     | 0     | 0     |
| $s_2$    | 0     | 0     | 0     |
| $s_3$    | 0     | 0     | 1     |
| $s_4$    | 0     | 0     | 0     |

Matriz Q tras el primer episodio de aprendizaje

# Q-Learning - ejemplo



MDP determinista

En un segundo episodio, el agente ejecuta la secuencia  $s_1 \xrightarrow{a_2} s_3 \xrightarrow{a_2} s_2 \xrightarrow{a_2} s_4$ . Si asumimos un valor de  $\gamma = 0,5$ , las actualizaciones sobre la tabla Q que se realizan son:

- $Q(s_1, a_2) = \mathcal{R}(s_1, a_2) + \gamma \arg_a \max Q(s_3, a) = 0 + \gamma \max(0, 0, 1) = \gamma = 0,5$
- $Q(s_3, a_2) = \mathcal{R}(s_3, a_2) + \gamma \arg_a \max Q(s_2, a) = 0 + \gamma 0 = 0$
- $Q(s_2, a_2) = \mathcal{R}(s_2, a_2) + \gamma \arg_a \max Q(s_4, a) = 1 + \gamma 0 = 1$

| $Q(s,a)$ | $a_1$ | $a_2$ | $a_3$ |
|----------|-------|-------|-------|
| $s_1$    | 0     | 0,5   | 0     |
| $s_2$    | 0     | 1     | 0     |
| $s_3$    | 0     | 0     | 1     |
| $s_4$    | 0     | 0     | 0     |

Matriz Q tras el segundo episodio de aprendizaje

Matriz Q óptima final

| $Q^*(s, a)$ | $a_1$ | $a_2$ | $a_3$ |
|-------------|-------|-------|-------|
| $s_1$       | 0,5   | 0,5   | 0,25  |
| $s_2$       | 0,25  | 1     | 0,5   |
| $s_3$       | 0,5   | 0,5   | 1     |
| $s_4$       | 0     | 0     | 0     |

# Q-Learning

Con acciones y refuerzos indeterministas:

$$Q_n(s, a) \leftarrow (1 - \alpha_n)Q_{n-1}(s, a) + \alpha_n \{r + \gamma \max_{a'} Q_{n-1}(s', a')\}$$

$$\alpha_n \leftarrow \frac{1}{1 + \text{visitas}_n(s, a)}$$

↖  
número total de veces que el par estado-acción ha sido visitado

# Práctica con Q-Learning

Aprender comportamiento de seguir una línea coloreada en el suelo. Detalles:

1. No hay una meta (punto) final. El objetivo es que el Khepera recorra y siga la línea marcada en el suelo con diferente color (negro en el ejemplo proporcionado). Se incorpora además un sencillo control de evitar obstáculos (que no se aprende).
2. Se usan los sensores de infrarrojos en el control de evitación de obstáculos y los sensores de infrarrojos inferiores en el módulo de comportamiento de seguimiento de la línea. Este módulo se implementa con una matriz Q.



# Práctica con Q-Learning

## 3. Definir inicialmente 3 estados:

- S1: Khepera abandona línea por la izquierda

$\text{infrared\_sensors}[9] > 750$


$\text{infrared\_sensors}[11] < 500$

- S2: Khepera abandona línea por la derecha


$\text{infrared\_sensors}[10] > 750$

$\text{infrared\_sensors}[8] < 500$

- S3: resto casos



Estado S1



## 4. Definir 3 acciones:

- A1: girar derecha
- A2: girar izquierda
- A3: avanzar en línea recta

# Práctica con Q-Learning

5. ¿Cómo definir refuerzo inmediato ante cada acción?:

5.1 No se puede definir sabiendo a priori cuál es la acción óptima en cada estado. Es decir, no se puede poner en el código que si hace A1 en S1 entonces refuerzo fantástico. Eso no vale, porque ¡no está aprendiendo de la experiencia!, sino de vuestra inmensa sabiduría a priori.

5.2 El refuerzo inmediato se debe definir en función de lo que el robot experimenta ante cada acción. Por ejemplo:

- Si valor previo de un sensor no detecta negro y después de la acción sí-> refuerzo positivo.
- Si valor previo de un sensor no detecta negro y después de la acción tampoco-> refuerzo negativo.

Los valores anteriores se podrían matizar en función de si son los sensores inferiores centrales (9 y 10) o los laterales (8 y 11).

# Práctica con Q-Learning

Resumen para la práctica:

1. Programar 3 movimientos/acciones básicas.
2. Programar función que determine el estado actual.
3. Después de realizar una acción, programar función que establece un valor numérico de refuerzo (positivo o negativo).
4. Actualizar la matriz Q (3x3), con la fórmula de entornos no deterministas:

$$Q_n(s, a) \leftarrow (1 - \alpha_n)Q_{n-1}(s, a) + \alpha_n\{r + \gamma \max_{a'} Q_{n-1}(s', a')\}$$

5. Después de cada acción, interviene el módulo de evitar obstáculos (no aprendido)

Notas adicionales:

El parámetro  $\gamma$  lo podéis dejar en un valor estándar de 0.5. El parámetro  $\alpha$  lo mismo, o podéis calcularlo en función de la estadística de visita a estados (fórmula en página previa).

Cuando se está aprendiendo/refinando la matriz Q (inicializada con valores a 0), el agente tiene que “explorar”, es decir, elegir acciones aleatorias para poder rellenar los valores de la matriz Q. Cuando la matriz Q está ya bien refinada, se puede cambiar a “explotación”, eligiendo la mejor acción en cada estado (concepto de política óptima). Por tanto, a la hora de elegir qué acción tomar (y cambiar la matriz Q), podéis empezar con una probabilidad de 1 de elegir acción aleatoria e ir decrementando esa probabilidad paulatinamente, hasta un valor máximo de iteraciones (sobre 500, donde la matriz Q ya debería estar refinada). Es decir, en la iteración 500 siempre se elegiría la mejor acción indicada en la matriz Q.